Taller: Entrada multimodal y audio

Desarrollo de Aplicaciones con IA

Objetivo y condiciones

Objetivo: usar un modelo con visión y un modelo de transcripción de audio sobre el dominio del proyecto, medir la calidad de sus resultados y entender sus límites.

Punto de partida: los ejemplos de clase `multimodal.py` y `audio_input.py`, y el README del repositorio compartido en clase. Los modelos de referencia en Groq son `qwen/qwen3.8-27b` para imágenes y `whisper-large-v3-turbo` o `whisper-large-v3` para audio. Se puede usar otro proveedor si lo consideran mejor.

Límites que deben conocer (según la documentación de visión y de voz a texto de Groq. Para los modelos diferentes, deben validar los límites de cada proveedor):

- Visión con `qwen/qwen3.8-27b`: máximo 3 imágenes por solicitud y 20 MB por solicitud. Cada imagen cuenta como 2.048 tokens de entrada.
- Audio: archivos de hasta 25 MB en el plan gratuito, en formatos como wav, mp3, m4a, ogg o webm. Cada solicitud se cobra como mínimo por 10 segundos.

Parte 1. Visión sobre imágenes del dominio (50 %)

Reúnan al menos 5 imágenes de su dominio. Ejemplos: la foto de una placa o pieza (manuales técnicos), un fragmento escaneado de una norma (leyes), una fórmula o resultado de laboratorio ficticio (historia médica), una figura o tabla de un artículo (documentos académicos).

1. **Pregunta sobre una imagen.** Envíen una imagen local en base64 con una pregunta del dominio, como en `multimodal.py`. Muestren la pregunta, la imagen y la respuesta.
2. **Extracción estructurada.**
   - Definan un esquema con al menos 5 campos útiles para su dominio.
   - Pidan al modelo que extraiga esos campos de 3 imágenes, con salida en JSON.
   - Validen el JSON en el código: si no cumple el esquema, el programa lo informa en lugar de fallar.
   - Comparen campo por campo lo extraído con el valor real que ustedes leen en la imagen y reporten el porcentaje de aciertos.
3. **Varias imágenes en una solicitud.** Envíen 2 o 3 imágenes relacionadas en un mismo mensaje y pidan una comparación o un resumen conjunto.
4. **Un error provocado.** Provoquen un error a propósito: un tipo de imagen mal declarado, una imagen demasiado grande, más imágenes de las permitidas o un modelo sin visión. Muestren el mensaje que devuelve la API y expliquen su causa.

Parte 2. Audio y transcripción (50 %)

Graben al menos 4 audios cortos (10 a 30 segundos) con preguntas sobre su dominio. Que hablen al menos dos integrantes distintos y que uno de los audios tenga ruido de fondo. Usen términos técnicos propios del dominio en las preguntas.

1. **Transcripción desde archivo.** Presenten la transcripción del audio.
2. **Respuesta.** Pasen la transcripción al modelo para que responda.

Entrega

1. **Carpeta** `taller_multimodal/` en el repositorio del proyecto, con:
   - Los scripts o notebooks de cada parte, ejecutables de principio a fin.
   - Las imágenes y audios usados (o un enlace si superan el tamaño razonable para GitHub).
   - Un `README.md` corto con cómo ejecutar cada parte y qué variables de entorno se necesitan.
   - Ninguna clave de API en el código ni en el historial de commits.
2. **Informe en Word o PDF**, siguiendo la plantilla de entrega de este documento, con capturas de la ejecución y la explicación de los resultados de cada punto.

Resumen de la calificación

El taller se califica sobre 50 puntos.

Criterio	Parte	Puntos
1. Preguntas sobre imágenes (1.1 y 1.3)	Parte 1	7.5
2. Extracción estructurada (1.2)	Parte 1	12.5
3. Error provocado (1.4)	Parte 1	5
4. Transcripción desde archivo (2.1)	Parte 2	12.5
5. Respuesta a partir de la transcripción (2.2)	Parte 2	12.5
Total		**50**

Plantilla de entrega

Completen cada sección y reemplacen los textos en gris por su contenido. Pueden agregar filas a las tablas. Entreguen el informe en Word o PDF.

Datos del grupo

Asignatura	Desarrollo de Aplicaciones con IA
Actividad	Taller: Entrada multimodal y audio
Integrantes	Juan David Cruz Rojas Joan Sebastian Lara Fuenmayor
Repositorio (URL)	https://github.com/jdcr1505/taller_multimodal.git

Parte 1. Visión

1.1 Pregunta sobre una imagen

Imagen (captura)	
Pregunta	Observa la imagen e identifica los componentes electrónicos presentes. Explica cuál es la función de cada uno y cómo interactúan para encender el LED.
Respuesta del modelo	Respuesta: ## Componentes electrónicos presentes Al observar la imagen (y sus ampliaciones) se distinguen **cinco elementos** que forman un circuito básico de encendido de un LED: | # | Componente | Aspecto en la imagen | |---|----------|--------------------| | 1 | **Pila de 9 V** | Batería rectangular negra/verde con el símbolo **“+”** y las leyendas *“WARNING: Install correctly (+/−). Do not charge”* y *“Made in USA”*. | | 2 | **LED (diodo emisor de luz)** | Componente blanco translúcido con forma de gota y **dos patas metálicas** (una más larga = ánodo, una más corta = cátodo). Está **encendido**. | | 3 | **Resistor** | Pequeño cilindro beige con **bandas de colores** (código de valor) y dos patas dobladas en “L” para insertarse en la protoboard. | | 4 | **Cables de conexión** | Un cable **rojo** y uno **negro** con los extremos pelados (cobre al descubierto) que se clavan en los orificios de la protoboard. | | 5 | **Protoboard (placa de prototipado)** | Base gris con rejilla de agujeros sobre una suela azul; permite armar el circuito **sin soldar**. |

Función de cada componente

1. **Pila de 9 V (fuente de alimentación):** Almacena energía química y la convierte en una **diferencia de potencial (voltaje) de 9 V** entre sus terminales positivo (+) y negativo (−). Es el “motor” que empuja los electrones por el circuito.

2. **LED (carga / indicador luminoso):** Es un **diodo semiconductor** que solo conduce en un sentido (de ánodo a cátodo). Cuando por él circula corriente en el sentido correcto, los electrones recombinan con huecos en la unión y liberan energía en forma de **fotones → luz visible** (en este caso, luz blanca).

3. **Resistor (limitador de corriente):** Su función es **reducir la intensidad de corriente** que llega al LED a un valor seguro (típicamente 10–20 mA). Sin él, los 9 V de la pila harían circular una corriente excesiva que **quemaría el LED en milisegundos**. Su valor se lee por las bandas de color (ley de Ohm: R = (V_fuente − V_LED) / I_LED).

4. **Cables rojo y negro (conductores):** Son “caminos” de baja resistencia que **transportan la corriente** entre la pila, el resistor y el LED. Por convención, el rojo va al polo positivo y el negro al negativo.

5. **Protoboard (medio de interconexión):** Sus pistas internas (en forma de “U” bajo cada fila de agujeros) **unen eléctricamente** los terminales que se insertan en el mismo grupo, permitiendo armar y desarmar el circuito sin soldadura.

Cómo interactúan para encender el LED (flujo del circuito)

El circuito es una **malla en serie** que parte y termina en la pila:

1. El **polo positivo (+)** de la pila de 9 V se conecta por el **cable rojo** a un punto de la protoboard.
2. Desde ese punto, la corriente pasa por el **resistor**, que “frena” la intensidad hasta el valor adecuado para el LED.
3. La corriente sale del resistor y entra por el **ánodo** (pata más larga) del **LED**.
4. Atraviesa la unión del diodo (donde se genera la luz) y sale por el **cátodo** (pata más corta).
5. Desde el cátodo, el **cable negro** devuelve la corriente al **polo negativo (−)** de la pila, **cerrando el circuito**.

Al estar el lazo cerrado y con la polaridad correcta (ánodo a +, cátodo a −), fluye una corriente limitada por el resistor y el LED **emite luz**, tal como se ve encendido en la imagen. Si se invirtiera la polaridad del LED o se quitara el resistor, el LED no encendería o se dañaría, respectivamente.

> **En resumen:** la pila *provee* el voltaje, el resistor *protege* limitando la corriente, el LED *convierte* esa corriente en luz, los cables *conducen* la corriente y la protoboard *une* todo sin soldar. Juntos forman el circuito en serie mínimo para encender un LED de forma segura.

Análisis: ¿es correcta? ¿por qué?	Sí, en general la respuesta es correcta. El modelo identificó bien los componentes que se ven en la foto (pila de 9 V, LED encendido, resistencia, cables y protoboard) y explicó para qué sirve cada uno. También describió bien cómo circula la corriente para encender el LED: sale de la pila, pasa por la resistencia, entra por el ánodo del LED y regresa por el cátodo. **¿Por qué?** Porque lo que dice sobre electrónica es cierto: la resistencia limita la corriente para que el LED no se queme con los 9 V, y el LED solo funciona si se conecta en el sentido correcto. Además se apoyó en detalles reales de la imagen, como el símbolo "+" y los textos de la pila. Pero su respuesta no fue perfecta, tuvo algunos errores. Habló de "ampliaciones" de la imagen cuando solo se le pasó una foto. Dijo que había un cable rojo y uno negro, pero en la foto hay tres, porque se logra ver un cable rojo sobre la protoboard. Tampoco dio el valor de la resistencia, ya que las bandas no se alcanzan a leer (lo cual es entendible). Y el camino exacto de la corriente es una suposición lógica, no algo que se pueda confirmar viendo la foto.

1.2 Extracción estructurada

Esquema

Campo	Tipo	Descripción
componente	String	Nombre del componente
valor	String	Valor nominal del componente
unidad	String	Unidad de medida
terminales	Integer	Cantidad de terminales
funcion	String	Función dentro del circuito
referencia	String	Referencia o identificación visible

Tabla de aciertos

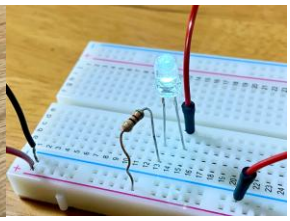
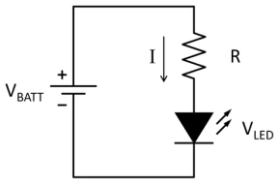
Imagen	Campo	Valor real	Valor extraído	¿Correcto? (Sí/No)
comp_1_resistencia	componente	Resistencia	Resistor	Sí
comp_1_resistencia	valor	220	220	Sí
comp_1_resistencia	unidad	Ω	Ω	Sí
comp_1_resistencia	terminales	2	2	Sí
comp_1_resistencia	funcion	Limitar corriente	Limitar el flujo de corriente eléctrica en el circuito	Sí
comp_1_resistencia	referencia	rojo-rojo-marrón-dorado	null	No

Imagen	Campo	Valor real	Valor extraído	¿Correcto? (Sí/No)
comp_2_capacitor	componente	Condensador electrolítico	Condensador electrolítico radial	Sí
comp_2_capacitor	valor	100	100	Sí
comp_2_capacitor	unidad	µF	µF	Sí
comp_2_capacitor	terminales	2	2	Sí
comp_2_capacitor	funcion	Almacenar energía	Almacenamiento de carga eléctrica, filtrado y desacoplamiento de señal	Sí
comp_2_capacitor	referencia	100µF 25V	25V 100µF	Sí
comp_3_transistor	componente	Transistor NPN	Transistor	Sí
comp_3_transistor	valor	null	null	Sí
comp_3_transistor	unidad	null	null	Sí
comp_3_transistor	terminales	3	3	Sí
comp_3_transistor	funcion	Amplificar	Transistor NPN de pequeña señal para amplificación y conmutación	Sí
comp_3_transistor	referencia	BC547	BC547	Sí

Porcentaje de aciertos	17 de 18 campos = 94,4 %
¿Cómo se valida el JSON en el código?	El programa busca el objeto JSON dentro de la respuesta del modelo, por si lo envía envuelto en texto o en un bloque ```json, y lo convierte con json.loads. Luego lo valida con un modelo de Pydantic que pide que los seis campos del esquema estén llenos, no permite campos extra y pide que el campo terminales sea un número entero. Los demás campos pueden ser texto o null. Si el JSON está mal formado o no cumple el esquema, el programa no se detiene: imprime el motivo del error y cuenta esos campos como incorrectos. En la ejecución, las tres respuestas pasaron la validación. Para mostrar el caso de error se usó la opción --demo-invalido, que prueba tres entradas malas: campos faltantes, un entero escrito como texto y una respuesta sin JSON.

Análisis de los errores de extracción	La comparación automática dio 12 de 18 campos (66,7 %), pero era demasiado literal: marcó como incorrectas respuestas que sí eran válidas, como “Resistor” en vez de “Resistencia”, funciones escritas con más palabras, o “25V 100µF” en vez de “100µF 25V”. Al revisar manualmente, con el criterio de que el significado sea el mismo, los aciertos suben a 17 de 18 (94,4 %). El único error fue la referencia de la resistencia: el modelo devolvió null en lugar de “rojo-rojo-marrón-dorado”. Sin embargo, el modelo debió leer, porque acertó el valor de 220 Ω, que solo se obtiene de los colores, ya que en la imagen no hay nada relacionado a ese número. El fallo viene de que el prompt pedía la “referencia visible” y el modelo entendió texto impreso, que la resistencia no tiene. Es un problema de cómo se definió el campo, no de visión. Además, acertó todo lo impreso, como “100µF 25V” y “BC547”, y cuando no encontró un dato prefirió dejarlo en null antes que inventarlo. En el transistor puso “Transistor” en el campo componente y dejó el tipo NPN en la función. Es una diferencia menor que se aceptó como correcta.

1.3 Varias imágenes en una solicitud

Imágenes enviadas (capturas)	  
Pregunta	Te envío 3 imágenes, sin primeros planos adicionales. Describe cada una por separado, cuenta los cables de la protoboard, lee las bandas de la resistencia (la dorada es la última) y dime si el diagrama coincide con el montaje. Si algo no se ve con claridad, dilo. Máximo 200 palabras.
Respuesta del modelo	Respuesta: **Imagen 1:** Placa Arduino UNO (azul) sobre mesa de madera, vista general. Sin protoboard ni cables. **Imagen 2:** Protoboard blanca con un LED azul encendido y una resistencia de película (beige). Cables conectados: **4** (rojo con conector azul al riel +, rojo con conector azul a la derecha, negro y rojo/marrón pelado a la izquierda). Bandas de la resistencia (dorada última): **marrón-negro-rojo-dorado → 1-0-×10² = 1 kΩ** (±5 %). **Imagen 3:** Diagrama esquemático: fuente V_BATT en serie con R y el LED (V_LED), corriente I descendente.

	Coincidencia: Sí, en topología: el montaje es un circuito serie fuente-resistencia-LED (rojo al riel +, negro al riel −), igual que el esquema. **No se ve con claridad:** la conexión exacta de la resistencia al riel negativo y la polaridad del LED (pata larga/corta); los cables pelados del riel + izquierdo resultanambiguos, por lo que no puedo confirmar con certeza que la resistencia esté en serie como dibuja el diagrama.
Análisis	La respuesta es en su mayoría correcta. El modelo describió bien las tres imágenes: la placa Arduino UNO sola sobre una mesa, la protoboard con un LED encendido y una resistencia, y el diagrama con una fuente, una resistencia y un LED en serie. Concluyó que el montaje coincide con el diagrama, y eso es cierto: el circuito va del riel positivo a la resistencia, luego al LED y de su cátodo al riel negativo. También respetó el límite de palabras y señaló al final lo que no se distingue con claridad. Tuvo varios errores. Contó 4 cables, pero la imagen está recortada y los dos cables rojos con conector son en realidad el mismo cable (va del cátodo del led al – de la protoboard), así que hay 3. Dijo que el cable rojo va al riel positivo, cuando va del cátodo del LED al riel negativo. Leyó las bandas de la resistencia como marrón-negro-rojo-dorado (1 kΩ), cuando en la imagen son verde, café, negro y dorado (51 Ω). Y se contradijo: afirmó que el montaje coincide con el diagrama y luego dijo que no podía confirmar que la resistencia esté en serie.

1.4 Error provocado

Qué se hizo para provocarlo	Se envió la imagen 01_circuito_led junto con una pregunta de texto a un modelo que solo trabaja con texto (openai/gpt-oss-20b), en lugar del modelo de visión qwen/qwen3.8-27b. El mensaje llevaba el contenido en formato multimodal: una lista con un bloque de texto y un bloque de imagen en base64.
Mensaje de error (captura)	
Causa del error	El modelo openai/gpt-oss-20b es solo de texto, así que espera que el contenido del mensaje sea una cadena de texto simple. Al enviarle una lista con texto e imagen, la API lo rechazó con un error 400 (solicitud inválida): messages[0].content must be a string, es decir, el campo content del primer mensaje debe ser un string. Solo los modelos con visión, como qwen/qwen3.8-27b, aceptan el contenido como una lista con bloques de imagen. El error se corrige usando un modelo con capacidad de visión.

Parte 2. Audio

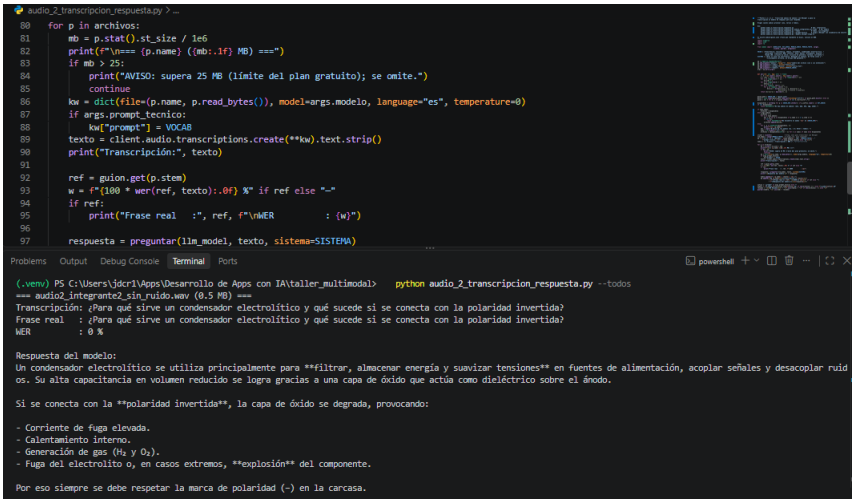
2.1 Transcripción desde archivo

Audio	Hablante	Condición (con/sin ruido)	Duración (s)	Lo que se dijo	Transcripción
audio1_integrante1_sin_ruido	Integrante 1	Sin	15	¿Cuál es la diferencia entre una resistencia de 220 ohmios y una de 1 kiloohmio, y cómo afecta esto al paso de la corriente en un circuito?	¿Cuál es la diferencia entre una resistencia de 220 ohmios y una de 1 kilo ohmio? ¿Y cómo afecta esto al paso de la corriente en un circuito?
audio2_integrante2_sin_ruido	Integrante 2	Sin	15	¿Para qué sirve un condensador electrolítico y qué sucede si se conecta con la polaridad invertida?	¿Para qué sirve un condensador electrolítico y qué sucede si se conecta con la polaridad invertida?
audio3_integrante1_con_ruido	Integrante 1	Con	15	Explícame cómo funciona un transistor NPN y cuál es la diferencia entre su colector, base y emisor.	Explica a mí cómo funciona un transistor NPN y cuál es la diferencia entre su colector, base y emisor.
audio4_integrante2_sin_ruido	Integrante 2	Sin	15	¿Cuál es la diferencia entre un circuito conectado en serie y uno conectado en paralelo?	¿Cuál es la diferencia entre un circuito conectado en serie y uno conectado en paralelo?

Observaciones sobre los errores de transcripción (audio con ruido, términos técnicos)	El WER fue de 11 % en el audio 1, 0 % en el 2, 18 % en el 3 (con ruido) y 0 % en el 4. Los términos técnicos se transcribieron bien en todos los audios: “resistencia”, “220 ohmios”, “condensador electrolítico”, “polaridad”, “transistor NPN”, “colector, base y emisor”, “serie” y “paralelo”. Los números y las unidades también salieron bien. Los errores fueron pequeños. En el audio 1, “1 kiloohmio” quedó escrito como “1 kilo ohmio” y la pregunta se dividió en dos por la puntuación, lo que no cambia el significado. En el audio 3, con ruido, “Explícame” se transcribió como “Explica a mí”. El ruido no afectó los términos técnicos. Con solo cuatro audios no se puede separar el efecto del ruido del hablante, porque los dos audios con errores son del integrante 1 y los dos sin errores son del integrante 2. Además, el WER es aproximado: cuenta como diferencia la puntuación pegada a las palabras, así que exagera los errores del audio 1.

2.2 Respuesta del modelo a partir de la transcripción

Audio	Transcripción enviada al modelo	Respuesta del modelo	¿Respuesta correcta y pertinente? (Sí/No)
audio1	¿Cuál es la diferencia entre una resistencia de 220 ohmios y una de 1 kilo ohmio? ¿Y cómo afecta esto al paso de la corriente en un circuito?	Explica que a igual tensión la resistencia menor deja pasar más corriente (ley de Ohm). Con 5 V: 220 Ω → 22,7 mA y 1 kΩ → 5 mA. Dice que con 220 Ω se disipa más potencia.	Sí
audio2	¿Para qué sirve un condensador electrolítico y qué sucede si se conecta con la polaridad invertida?	Sirve para filtrar, almacenar energía y suavizar tensiones. Con polaridad invertida la capa de óxido se degrada: fuga, calentamiento, gas y posible explosión.	Sí
audio3	Explica a mí cómo funciona un transistor NPN y cuál es la diferencia entre su colector, base y emisor.	Describe emisor (n), base (p) y colector (n), y cómo una pequeña corriente de base controla una corriente de colector mayor ($I_C = \beta \cdot I_B$), para amplificar o conmutar.	Sí
audio4	¿Cuál es la diferencia entre un circuito conectado en serie y uno conectado en paralelo?	En serie la corriente es la misma y el voltaje se reparte; en paralelo el voltaje es el mismo y la corriente se reparte. Si falla un componente en serie, todo se apaga.	Sí

Captura del flujo (código y salida): audio → transcripción → respuesta	
¿Los errores de transcripción afectaron la respuesta? ¿Cómo?	No. Los errores fueron en palabras comunes y no cambiaron el significado de la pregunta: “kilo ohmio” equivale a “kiloohmio” y “Explica a mí” se entiende como “Explícame”. Como los términos técnicos se transcribieron bien, el modelo respondió lo que se preguntaba en los cuatro audios. Un error en un término más importante como “transistor NPN” habría podido cambiar la respuesta, pero eso no ocurrió.
Conclusión	Whisper transcribió con buena calidad los cuatro audios, incluyendo los términos técnicos, los números y las unidades de electrónica, y los errores se limitaron a palabras comunes. El ruido de fondo del audio 3 no afectó los términos técnicos, aunque produjo un error en una palabra común. El modelo de lenguaje respondió de forma correcta y pertinente a las cuatro preguntas, incluso con transcripciones imperfectas. Con tan pocos audios no se puede concluir cuánto influye el ruido o el hablante; solo se observa que los errores fueron pequeños y no cambiaron las respuestas.

Dificultades y aprendizajes

Máximo media página: qué fue lo más difícil y qué aprendieron sobre los límites de estos modelos.

Dificultades	Lo más difícil fue lograr que el modelo de visión diera respuestas precisas en los detalles. Leyó mal los colores de las bandas de la resistencia en las imágenes con varios elementos, y en varias respuestas mencionó imágenes o primeros planos que no habíamos enviado. También tuvimos un problema técnico: el límite de tokens por minuto del plan gratuito de Groq produjo errores 429. Por último, evaluar los resultados de forma automática fue difícil: la comparación campo por campo fue demasiado estricta y el WER se afectó por la puntuación, por lo que tuvimos que revisar varios casos a mano.
Aprendizajes	Aprendimos que los modelos de visión sirven para identificar componentes y explicar el funcionamiento general de un circuito, pero fallan en detalles finos (como el código de colores de una resistencia), y pueden inventar elementos que no existen o suponer relaciones entre imágenes que no se pueden comprobar. Una pregunta más guiada, que pida describir cada imagen por separado y decir lo que no se ve, mejora las respuestas, pero no corrige todos los errores. En la extracción estructurada, validar el JSON con un esquema evita que el programa falle, y definir bien cada campo es importante: un campo ambiguo como “referencia” hizo que el modelo devolviera null aunque sí leía las bandas. En audio, Whisper transcribió bien los términos técnicos, los números y las unidades incluso con ruido de fondo, y el modelo de lenguaje respondió bien aunque la transcripción tuviera errores pequeños. Y para concluir, entendimos que cada modelo tiene límites de tamaño, de número de imágenes y de tokens que hay que conocer antes de usarlo.